

Губанова В.Е.

РТ5-61Б

Вариант 5

✓ Рубежный контроль №1

Тема: Технологии разведочного анализа и обработки данных.

Задача №1. Для заданного набора данных проведите корреляционный анализ. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Сделайте выводы о возможности построения моделей машинного обучения и о возможном вкладе признаков в модель.

Импортируем библиотеки pandas, matplotlib, seaborn

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn import linear_model, metrics, model_selection
```

Загрузка и первичный просмотр данных

```
data = pd.read_csv('Admission_Predict.csv')

data.head()

data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 400 entries, 0 to 399
Data columns (total 9 columns):
 #   Column                Non-Null Count  Dtype  
---  -
 0   Serial No.            400 non-null   int64   
 1   GRE Score              400 non-null   int64   
 2   TOEFL Score            400 non-null   int64   
 3   University Rating      400 non-null   int64   
 4   SOP                    400 non-null   float64  
 5   LOR                    400 non-null   float64  
 6   CGPA                   400 non-null   float64  
 7   Research               400 non-null   int64   
 8   Chance of Admit        400 non-null   float64  
dtypes: float64(4), int64(5)
memory usage: 28.3 KB
```

Проверка пропусков в данных

```
data.isnull().sum()
```

	0
Serial No.	0
GRE Score	0
TOEFL Score	0
University Rating	0
SOP	0
LOR	0
CGPA	0
Research	0
Chance of Admit	0
dtype: int64	

Пропуски отсутствуют, поэтому удаление строк или столбцов не требуется

Удалим столбец Serial No., так как он не несёт полезной информации.

```
data = data.drop(columns=['Serial No.'])
data.head()
```

	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit	
0	337	118	4	4.5	4.5	9.65	1	0.92	
1	324	107	4	4.0	4.5	8.87	1	0.76	
2	316	104	3	3.0	3.5	8.00	1	0.72	
3	322	110	3	3.5	2.5	8.67	1	0.80	
4	314	103	2	2.0	3.0	8.21	0	0.65	

Next steps: [New interactive sheet](#)


Корреляционный анализ

```
corr_matrix = data.corr()
corr_matrix
```

	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit	
GRE Score	1.000000	0.835977	0.668976	0.612831	0.557555	0.833060	0.580391	0.802610	
TOEFL Score	0.835977	1.000000	0.695590	0.657981	0.567721	0.828417	0.489858	0.791594	
University Rating	0.668976	0.695590	1.000000	0.734523	0.660123	0.746479	0.447783	0.711250	
SOP	0.612831	0.657981	0.734523	1.000000	0.729593	0.718144	0.444029	0.675732	
LOR	0.557555	0.567721	0.660123	0.729593	1.000000	0.670211	0.396859	0.669889	
CGPA	0.833060	0.828417	0.746479	0.718144	0.670211	1.000000	0.521654	0.873289	
Research	0.580391	0.489858	0.447783	0.444029	0.396859	0.521654	1.000000	0.553202	
Chance of Admit	0.802610	0.791594	0.711250	0.675732	0.669889	0.873289	0.553202	1.000000	

Next steps: [New interactive sheet](#)

```
plt.figure(figsize=(10,8))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')
plt.title('Корреляционная матрица')
plt.show()
```



Рассмотрим корреляцию признаков с Chance of Admit

```
corr_target = corr_matrix['Chance of Admit'].sort_values(ascending=False)
corr_target
```

	Chance of Admit
Chance of Admit	1.000000
CGPA	0.873289
GRE Score	0.802610
TOEFL Score	0.791594
University Rating	0.711250
SOP	0.675732
LOR	0.669889
Research	0.553202

dtype: float64

Наиболее сильную корреляцию с целевой переменной имеют:

- CGPA
- GRE Score
- TOEFL Score

Это означает, что именно эти признаки вносят наибольший вклад в модель.


Также наблюдается высокая корреляция между самими признаками (например, GRE и TOEFL), что указывает на возможную мультиколлинеарность.

✓ Выводы

1. Пропуски в данных отсутствуют.
2. Набор данных подходит для построения моделей машинного обучения.
3. Наиболее значимые признаки:
 - CGPA
 - GRE Score
 - TOEFL Score
4. Присутствует мультиколлинеарность между признаками.
5. Рекомендуемые модели:
 - Линейная регрессия (с регуляризацией)
 - Random Forest
 - Gradient Boosting

Дополнительные требования по группам: Для студентов группы PT5-61Б - для пары произвольных колонок данных построить график "Jointplot".

```
sns.jointplot(data=data, x='GRE Score', y='CGPA', kind='scatter', height=8)
plt.suptitle('Jointplot: GRE Score vs CGPA', y=1.02)
plt.show()
```



```
sns.jointplot(data=data, x='TOEFL Score', y='Chance of Admit ', kind='scatter', height=8)  
plt.suptitle('Jointplot: TOEFL Score vs Chance of Admit', y=1.02)  
plt.show()
```

